서강대학교 | 강화학습개론 | 2026년 2학기

경험만으로 최적 저축을 배울 수 있을까?

확률적 소비·저축 문제에서 Dynamic Programming과 DQN · PPO의 정책 및 경제적 후생 비교

박규태 학번: 20220521

GitHub https://github.com/kyu-tae-Park/consumption-saving-rl

FINAL PROJECT REPORT · PRESENTATION-FREE SUBMISSION

이번 프로젝트의 핵심 결과

전통적인 DP 최적정책을 기준으로, Model-free RL이 얼마나 가까이 학습하는지 평가

−36.503

DQN 평균 할인효용

DP-Matched: −36.255

94.4%

DP와 ±10%p 이내

DQN 저축률 정책의 grid-state 적중률

0.68%

후생 손실 (CEV)

DP-Matched 대비 평균 소비등가 손실

경제모형 설계 → DP benchmark → DQN / PPO 학습 → 5-seed 독립 평가

한 줄 결론 | 이 소규모 문제에서는 DP가 최적이지만, DQN은 전이모형을 직접 풀지 않고도 근접한 정책을 학습했다.

소비자는 매 기간 무엇을 결정하는가?

현재 소비의 만족과 미래 자산축적 사이의 선택에 소득 불확실성이 더해진 문제

현재 자산 a_t + 이자/원금 + 현재 소득 y_t $\quad m_t = R \cdot a_t + y_t$

저축률 z_t 선택

현재 소비 $c_t = (1-z_t)m_t$

이번 기간의 효용 $u(c_t)$을 결정

다음 자산 $a_{t+1} = z_t m_t$

미래 소비 가능성과 완충저축을 결정

예: a=1, 고소득 y=1, z=50% → m=2.00985 → c=1.004925, a′=1.004925

최적 정책은 “항상 몇 % 저축하자”가 아니라 자산과 소득 상태에 따라 달라지는 저축 규칙이다.

소득 위험: 두 상태 Markov 과정

현재 소득이 다음 기간의 소득분포를 결정하지만, 미래 상태는 확실하지 않다

HIGH INCOME | yH = 1.000

고소득 지속 확률 93.93%

LOW INCOME | yL = 0.472

저소득 지속 확률 60.80%

전이확률 P

$$\begin{bmatrix} 0.9393 & 0.0607 \\ 0.3920 & 0.6080 \end{bmatrix}$$

행=현재(H, L) / 열=다음(H, L)

실측 가계 데이터가 아닌, 두 소득 상태를 가진 합성 시뮬레이션 환경이다. 예비적 저축을 관찰하기 위한 단순화다.

경제모형을 강화학습 문제로 변환

상태·행동·보상·전이를 명시하여 소비-저축 최적화를 MDP로 구현

STATE · $s_t = (a_t, y_t)$

현재 자산(연속값)과 소득 상태(H/L)

ACTION · $z_t \in \{0,.05,\ldots,.95\}$

20개 이산 저축률 중 하나를 선택

REWARD · $u(c_t) = c_t^{1-}\sigma/(1-\sigma)$

σ=2에서는 u(c)=−1/c

TRANSITION · $s_t \rightarrow s_{t+1}$

자산은 결정적, 소득은 Markov 확률전이

목표: $\max\pi \; E\pi [\Sigma_t \beta^t \cdot u(c_t)]$ | $\beta = 0.9703$

Agent는 경제모형의 전이확률 P를 직접 입력받지 않고, 환경의 (s, a, r, s′) 경험을 통해 학습한다.

기존 게임이 아닌 사용자 정의 Gymnasium 환경

소비-저축 의사결정과 소득 위험을 반영한 ConsumptionSavingEnv를 직접 정의

01	**RESET**	초기 자산 1, 소득 H / 학습 중에는 다양한 초기 자산
02	**STEP**	agent가 20개 저축률 중 한 가지 선택
03	**REWARD**	CRRA 효용 계산, 자산축적, 소득 상태 전이
04	**NEXT**	새 (a′, y′)을 반환하고 학습을 반복

설계에서 중요한 점

- 소비 $c > 0$ 유지
- Borrowing 금지: $a' \geq 0$
- 경제학적 문제는 무한기간

학습 rollout은 200 step마다 인위적으로 초기화.
이는 경제모형의 종료 상태를 뜻하지 않음.

이 프로젝트의 핵심 기여 중 하나는 경제학 문제를 RL 학습 가능한 환경으로 명시적으로 구현한 것이다.

DP를 “정답 기준”으로 사용한 이유

모형의 전이를 알고 있는 소규모 문제에서는 Bellman value iteration으로 정책을 계산할 수 있음

$$V(a,y) = \max_z \left[u((1-z)(Ra+y)) + \beta \cdot E\{V(a',y')\} \right]$$

−36.218

DP-Fine

500개 next-asset grid에서 직접 선택

−36.240

DP-Matched

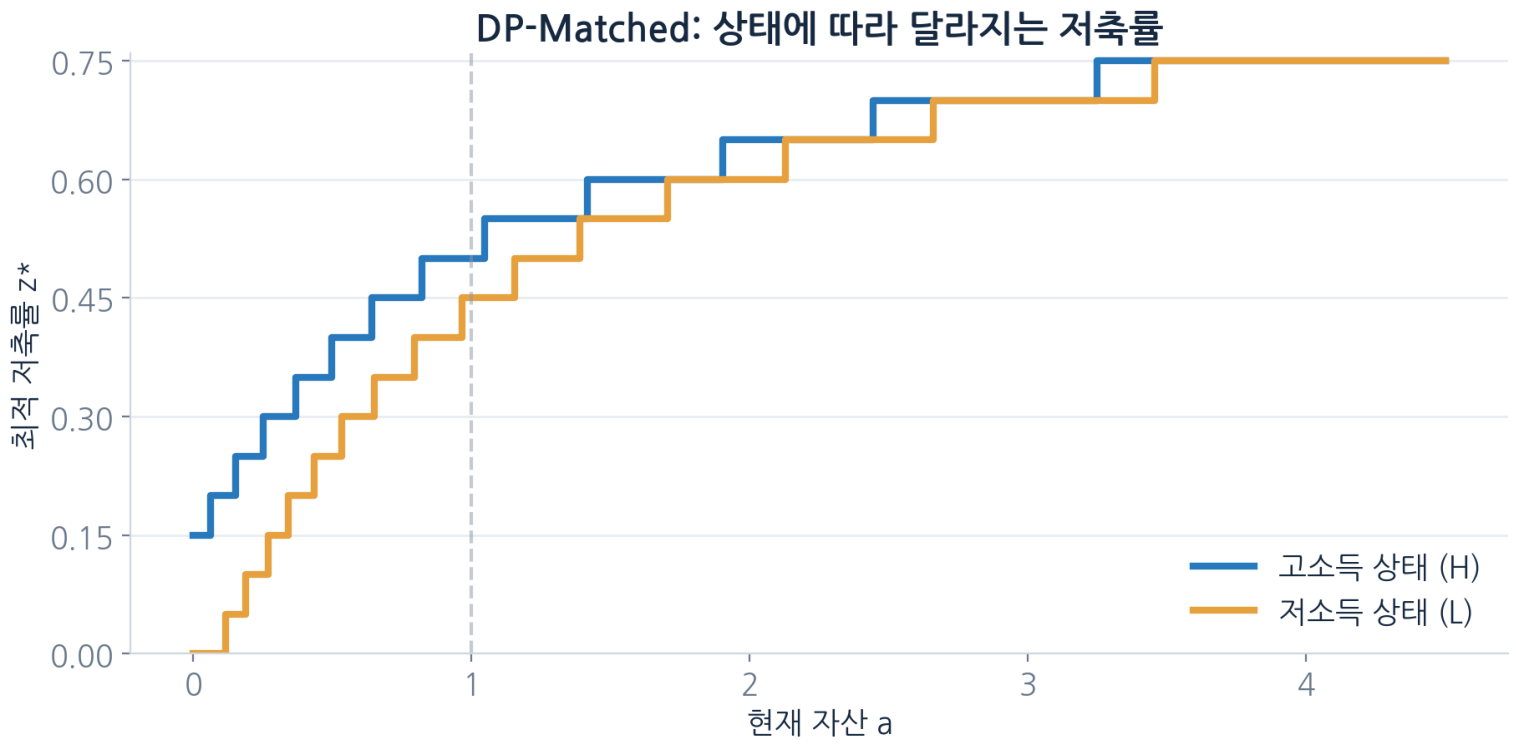
RL과 동일한 20개 저축률에서 선택

초기상태 (a=1, H)의 Bellman value 차이: 0.0221 → 이산 행동에 따른 손실은 작음

공정성: DQN/PPO 성능의 직접 비교 기준은 RL과 같은 action space를 가진 DP-Matched이다.

최적 저축률은 상태에 따라 움직인다

a≈1일 때 고소득자는 50%, 저소득자는 45%를 저축하는 것이 DP-Matched의 선택



HIGH: a≈1

저축률 50%

LOW: a≈1

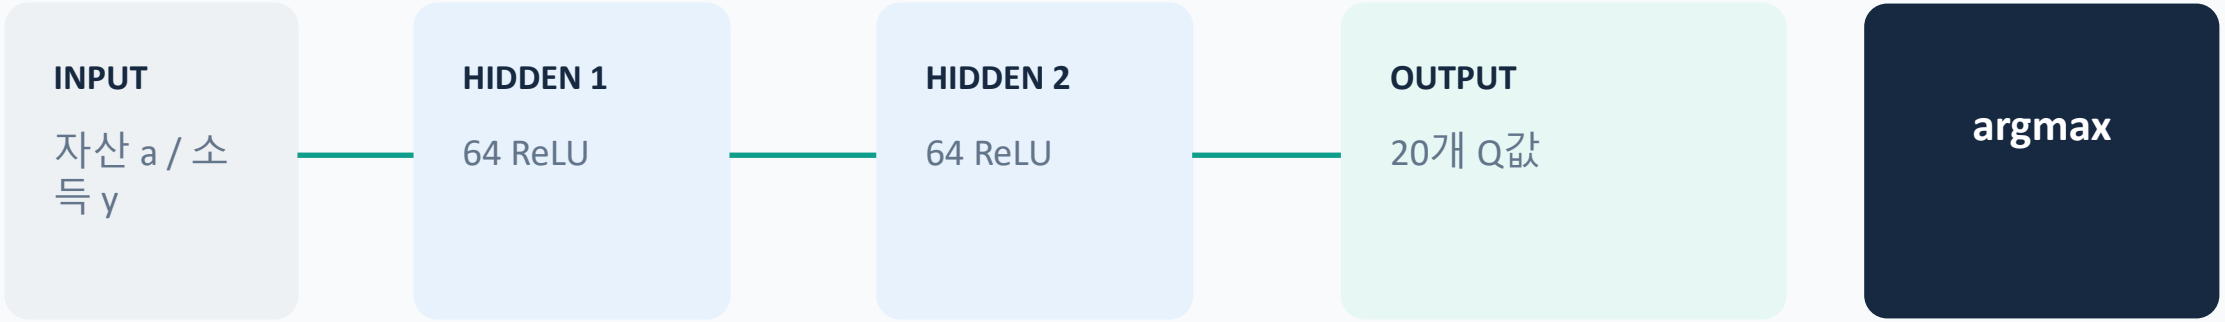
저축률 45%

두 소득상태와 자산 수준 모두 정책에 영향을 줌.
상단 구간은 자산 grid 상한(4.5)의 영향도 받음.

"언제나 50% 저축"보다 더 미세하게 상태에 적응하는 정책이 후생을 높이는지 검증한다.

DQN은 Q(s,a)를 근사해 저축률을 선택한다

Replay buffer와 target network를 사용한 model-free value-based 학습



가장 큰 Q → 저축률 선택

TD target: $r_t + \beta \cdot \max_{a'} Q_target(s_{t+1}, a')$ → MSE 학습

- Replay buffer 100k / batch 64
- Target network 500 step마다 갱신

핵심: Q-network에는 income transition matrix P를 직접 넣지 않는다. 관측 경험으로 Q값을 학습한다.

PPO는 가치가 아니라 정책 자체를 업데이트한다

DQN과 학습원리가 다른 actor–critic 계열을 동일한 20개 행동 공간에서 비교

DQN | Value-based

Q(s,a) 추정 → argmax를 통해 행동 선택

PPO | Policy-based / Actor–Critic

π(a|s) 개선 → 확률적 행동정책 학습

실험 과정에서의 설계 수정

Continuous PPO

저축률 경계(z≈0)로 policy collapse

정규화 Continuous PPO

[-1,1] action 변환 후에도 개선 부족

Discrete PPO

DQN과 20개 action 통일

이후 비교는 state·action·reward·transition을 통일해 알고리즘 차이에 집중했다.

학습·모델선택·테스트를 분리했다

성능이 좋은 checkpoint만 남기되, 최종 test는 validation과 독립적으로 평가

TRAIN

100,000 steps / seed

다양한 초기 자산과 소득
ε-greedy(DQN) / PPO update

VALIDATION

512 paths × 300

DQN: 5k 간격 평가
PPO: 10k 간격 평가

TEST

2,000 paths × 500

$(a_0, y_0)=(1,H)$
공통 test income shocks

학습 seed 5개: 0, 1, 2, 3, 4

Best validation checkpoint → Test

test는 모델 선택에 사용하지 않았다. RL 간 분산은 train seed 간 차이, path 평가오차와 구분한다.

성능을 네 방향에서 평가했다

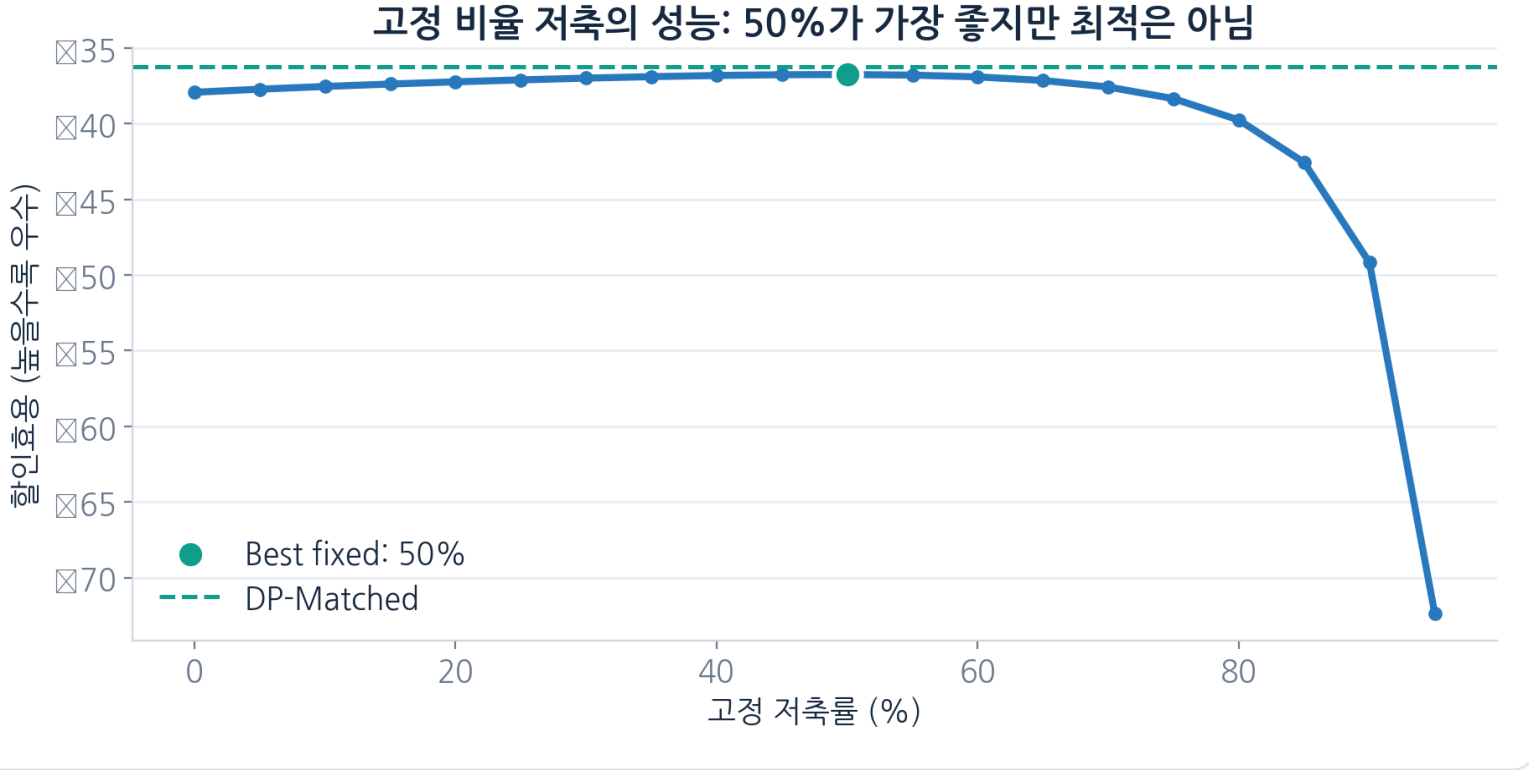
점수 하나가 아니라 효용·행동 정확도·경제적 후생·재현성을 함께 측정

01	**할인효용 ↑**	테스트 경로에서 $E[\Sigma \beta^t u(c_t)]$	높을수록 좋음 (음수값 포함)
02	**정책 오차(MAE) ↓**	평가 grid에서 $\lvert zRL(s) - zDP(s) \rvert$ 평균	0.05는 5%p 저축률 차이
03	**Within ±10%p ↑**	DP 최적 저축률과 10%p 이내 비율	근사정책의 실질적 정확도
04	**CEV 손실 ↓**	최적 정책과 같아지는 소비등가 보상	소비 %로 표현하는 후생 손실

신뢰구간 구분: RL=5개 training seed 평균의 t-기반 CI / DP·Fixed=2,000개 테스트 경로의 Monte Carlo CI

무작위 행동과 고정 저축률을 먼저 비교했다

RL의 성과를 해석하려면 “아무렇게나 행동하는 정책” 및 단순 규칙 대비 개선이 필요



Random policy

−78.114

Best fixed: 50%

−36.745

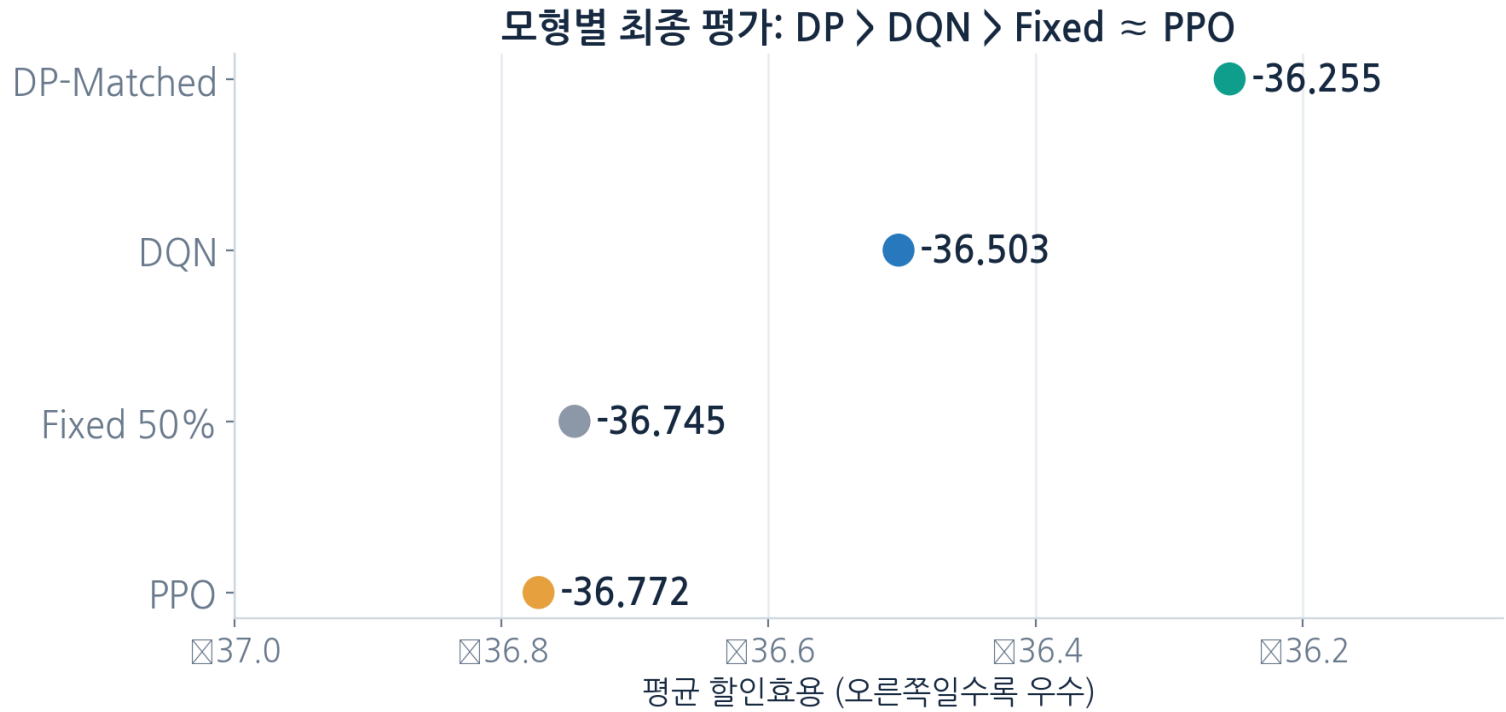
DP-Matched

−36.255

결론: 고정 50% 규칙은 의외로 강한 baseline이다. RL이 이를 넘으면 상태별 의사결정의 추가 가치가 있다.

최종 후생 순위: DP > DQN > Fixed ≈ PPO

모든 정책을 같은 초기상태와 테스트 소득 경로로 평가한 평균 할인효용



DQN – Fixed

+0.243 utility

DQN – DP

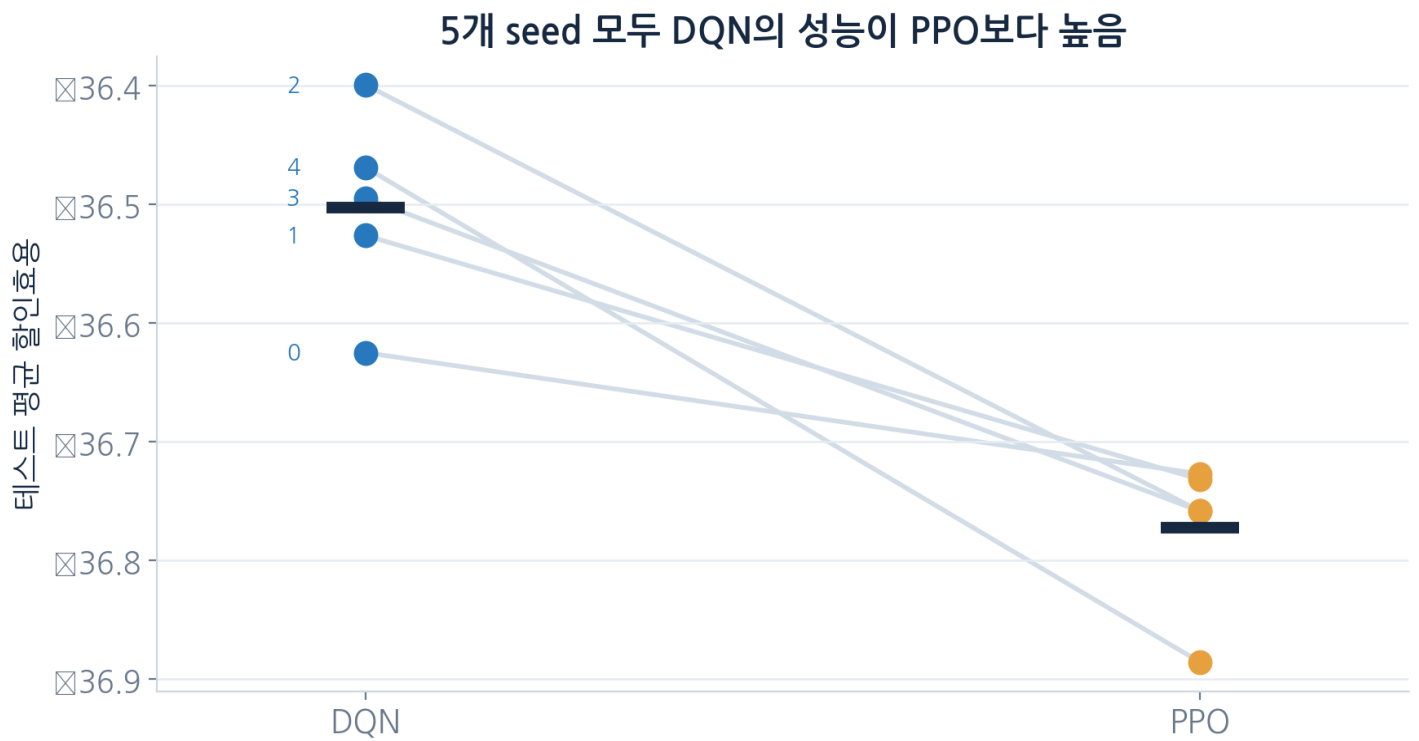
−0.248 utility

큰 값(덜 음수)이 더 좋은 효용이다.
여기서는 평균 점추정치 순위를 표시함.

DQN은 고정 50% 저축을 상회하면서 DP-Matched 해에 가까운 후생을 달성했다.

DQN은 다섯 개 seed 모두 PPO보다 높았다

훈련 변동성을 반영한 5-seed 비교; DQN 평균 −36.503, PPO 평균 −36.772



DQN 95% CI

[−36.605, −36.400]

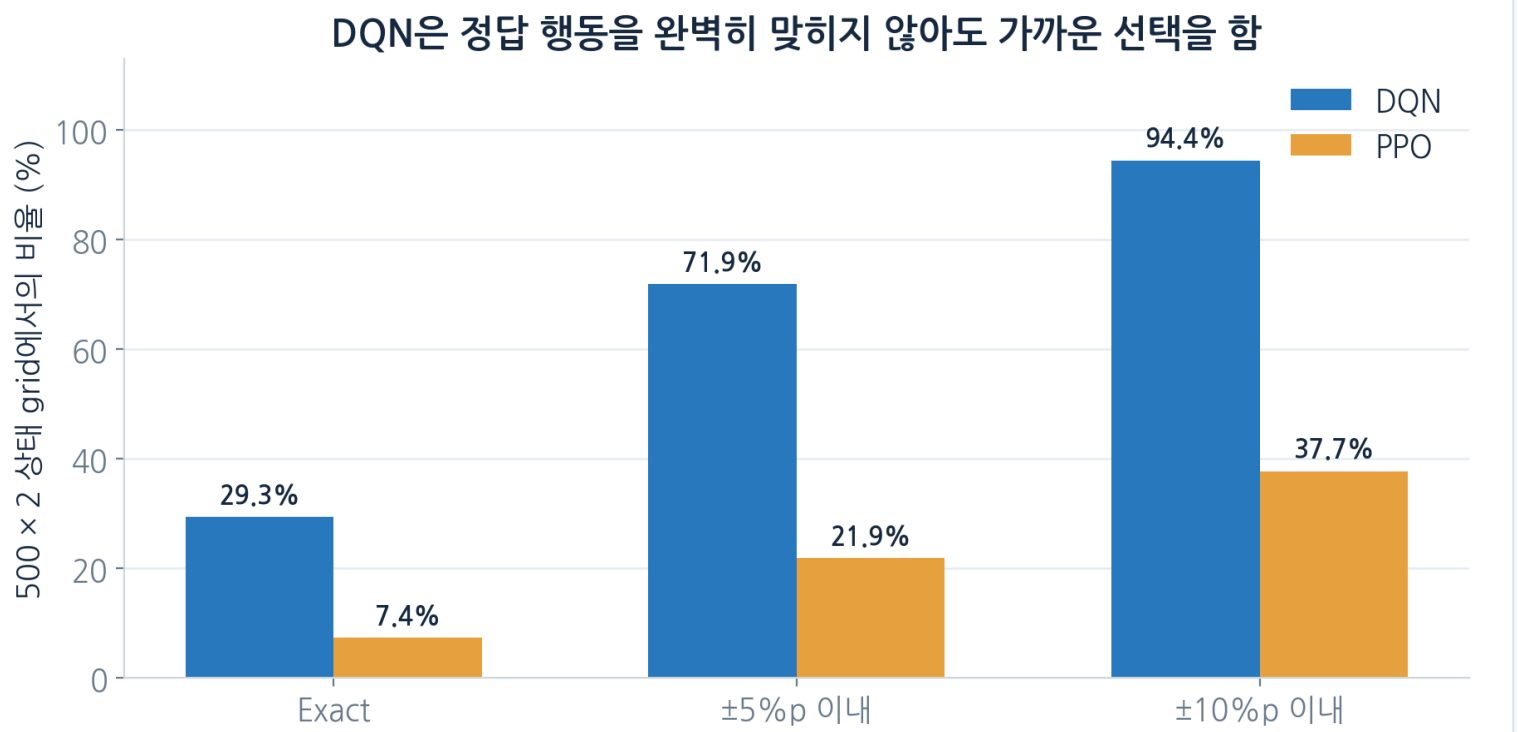
PPO 95% CI

[−36.853, −36.691]

RL 신뢰구간은 training seed 간 t-CI(n=5). 작은 표본이므로 불확실성 추정을 과도하게 일반화하지 않는다.

행동 자체도 DQN이 훨씬 정확했다

DP-Matched의 최적 저축률을 기준으로 500개 자산 × 2개 소득 = 1,000개 상태에서 비교



DQN Policy MAE

5.25%p

PPO Policy MAE

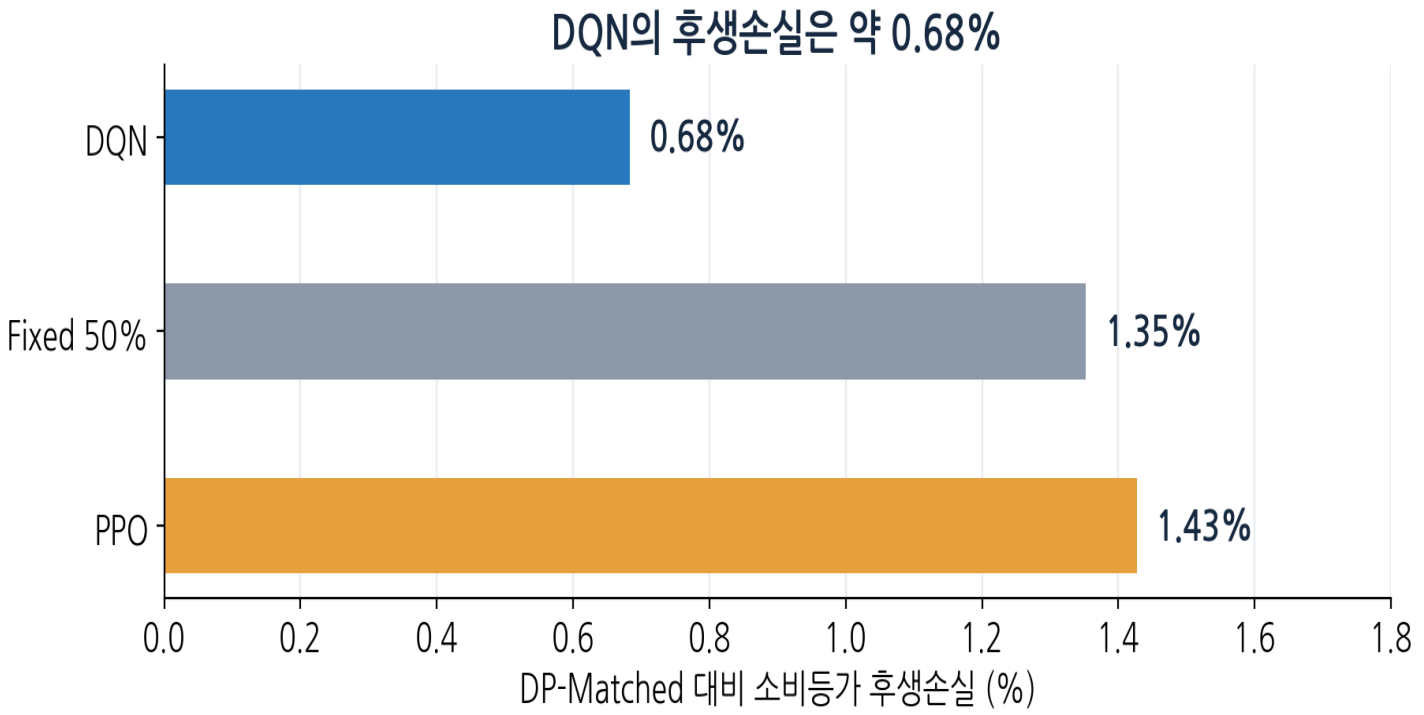
18.48%p

Exact agreement가 29.3%여도,
DQN은 94.4%의 상태에서
정답과 ±10%p 이내로 행동.

"정확히 같은 행동"만이 아니라, 근처 행동이 실제 후생을 얼마나 보존하는지를 함께 보아야 한다.

DQN의 후생손실은 소비의 약 0.68%

경제학적 해석을 위해 utility 차이를 Consumption Equivalent Variation(CEV)으로 변환



0.68%

DQN의 소비등가 손실

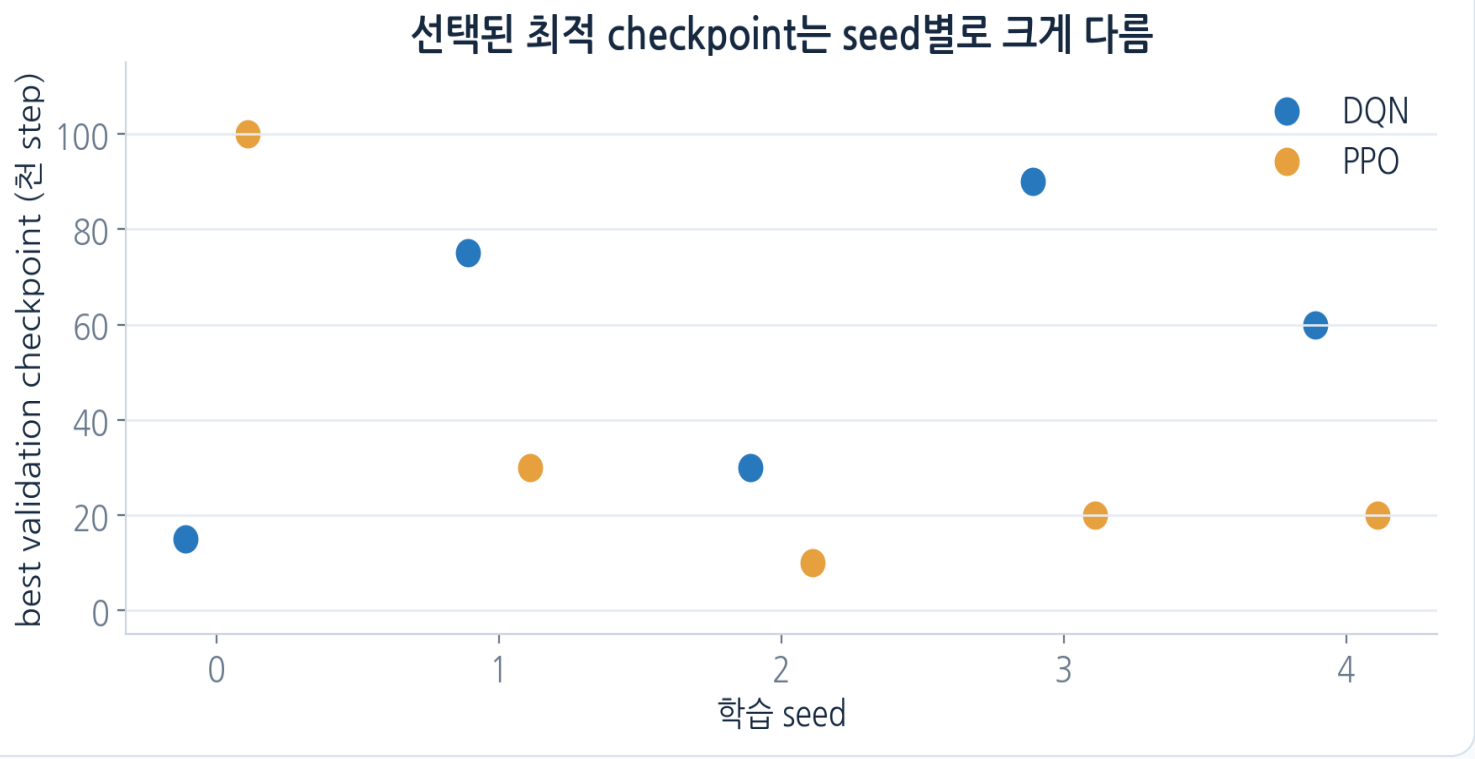
해석

DQN의 소비를 매 기간 약 0.68% 늘리면
DP와 같은 기대효용에 도달

CEV = [(V_DP / V_policy)^(1/(1−σ)) − 1]×100 | σ=2, 동일 CRRA 효용·평가경로 가정

더 오래 학습한다고 항상 좋은 정책이 나오지는 않았다

Validation checkpoint를 쓰게 된 실험상의 이유와 추가 알고리즘 실험을 정리



진단 요약

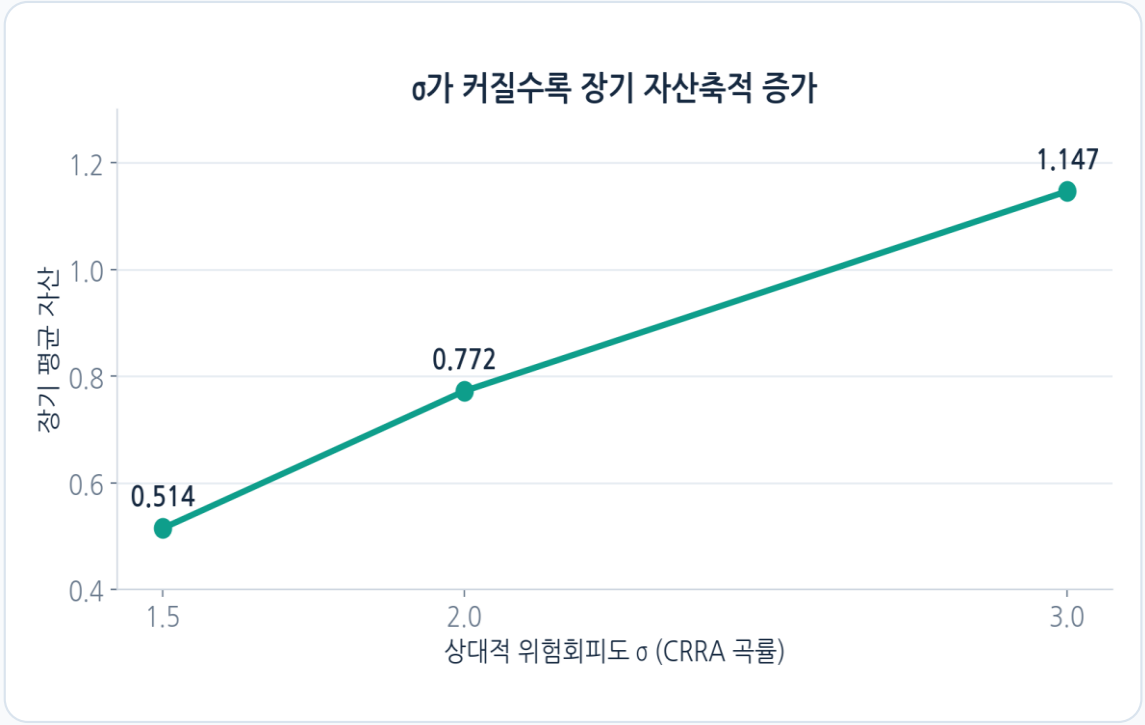
- DQN: best 15k~90k
- 최종 step보다 validation 기준 선택
- Double DQN은 명확한 개선 없음

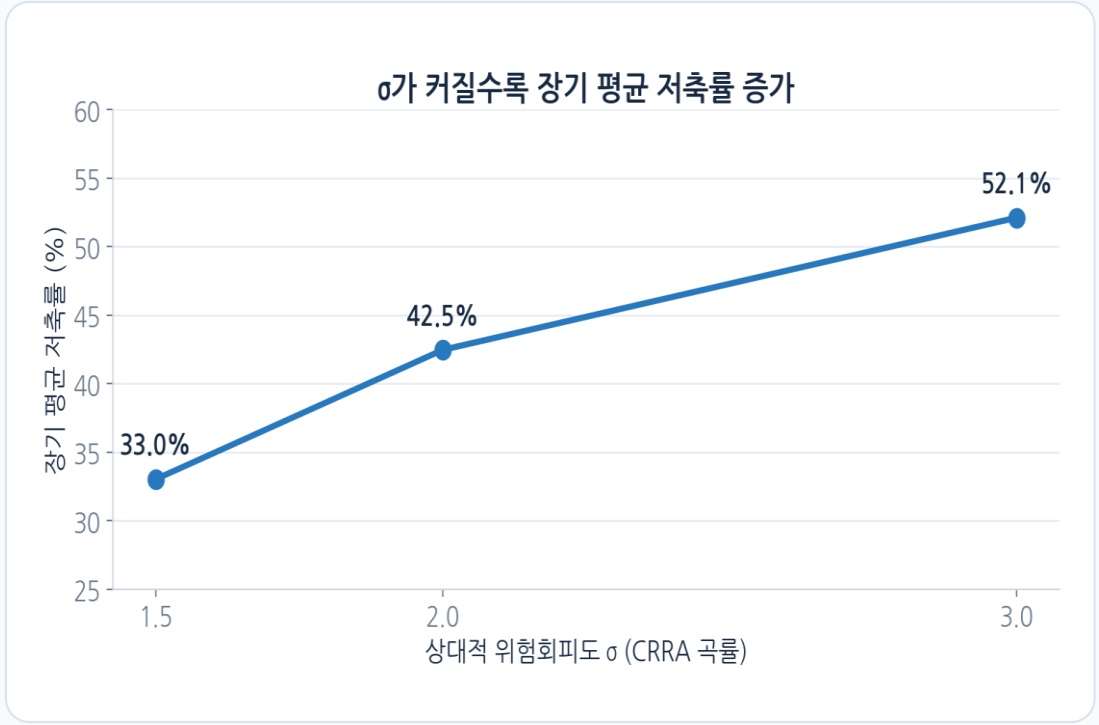
PPO 연속형 행동은 경계 collapse를 관찰하여
최종 연구에서는 discrete PPO로 통일.

실패 실험도 결과다: 좋은 checkpoint를 선택하는 방법 자체가 RL 실험 품질에 영향을 준다.

더 높은 CRRA 곡률에서 예비적 저축이 증가했다

σ = 1.5, 2.0, 3.0으로 바꾼 DP-Matched 비교정태; 나머지 경제환경은 고정





σ 1.5 → 2.0 → 3.0 | 평균 자산 0.514 → 0.772 → 1.147 | 저축률 33.0% → 42.5% → 52.1%

주의: σ는 위험회피도뿐 아니라 IES=1/σ도 함께 바꾼다. 순수한 위험회피의 인과효과라고 단정하지 않는다.

무엇을 보여주었고, 어디까지 일반화할 수 있나?

해석 가능한 작은 환경에서 RL의 가능성을 보이되, 수치·환경·알고리즘 한계를 명시

경제환경 단순화	2개 소득상태, 합성 Markov 소득, CRRA 효용. 실제 가계 데이터를 사용하지 않음.
DP 그리드 경계	DP는 자산 0~4.5에 제한. RL 환경은 자산 상한을 강제하지 않아 완전한 동등성은 아님.
연속행동·하이퍼파라미터	최종 비교는 5%p discrete action·제한된 예산/설정. PPO 일반적 열세를 뜻하지 않음.
추론 및 반복성	5 training seed, 고정 test paths. 정책 grid 평균은 방문확률을 가중하지 않음.

다음 연구: 자산 상한 정합화, 더 풍부한 소득 과정, 연속 제어(SAC 등), 다수 seed·환경 calibration 확장.

모형을 몰라도, 경험을 통해 동적 경제정책을 학습할 수 있다

정답의 대체라기보다, DP가 어려운 복잡한 환경으로 확장할 수 있는 가능성의 검증

DP-Matched −36.255 > DQN −36.503 > Fixed −36.745 ≈ PPO −36.772

01 문제의 정식화

경제학의 저축 의사결정을 상태·행동·보상이 있는 MDP로 구현

02 RL의 가능성

DQN은 정책 ±10%p 이내 94.4%, CEV 손실 0.68%

03 실험 설계의 중요성

동일 action 비교, 5-seed, validation checkpoint, 실패 실험 분석

최종 메시지 | Model-free DQN can learn a near-optimal saving policy without explicitly solving the Bellman equation.

재현성, 파일 구조, 생성형 AI 활용 고지

최종 학습 파일·저장 모델·결과표를 GitHub에서 확인할 수 있도록 구성

제출 저장소

https://github.com/kyu-tae-Park/consumption-saving-rl

- main.ipynb — 빠른 결과 확인
- experiments/full_training.ipynb — 5-seed 재학습
- models/ — DQN 5개(.pt), PPO 5개(.zip)
- results/ — 평가 CSV 및 그래프

생성형 AI 활용 범위

ChatGPT를 활용하여 연구설계 토의,
코드 초안 및 디버깅, 실험 해석,
README·보고서 구성의 도움을 받음.

실험은 Google Colab에서 실제 실행.
제출자는 코드·결과·해석의 검증 책임을 부담.

제출 전 확인: 첫 슬라이드의 [학번 입력]을 실제 학번으로 교체하고 PPT를 GitHub 및 Cyber Campus에 함께 업로드.

핵심 hyperparameter와 evaluation 기준

발표 없이 읽는 보고서이므로 주요 설정을 한 장에 모아 기술

항목	DQN	Discrete PPO
네트워크 / policy	MLP: 2 → 64 → 64 → 20	Stable-Baselines3 MlpPolicy
학습률 / optimizer	Adam, 1e−3	3e−4 (PPO default optimizer)
학습기간 / seed	100,000 steps × 5 seeds	100,000 timesteps × 5 seeds
batch / rollout	batch 64, replay 100k	batch 64, rollout 2,048
탐색 / 업데이트	ε:1 → .05 (첫 25k), target 500	GAE λ=.95, clip=.2, ent=.0
checkpoint	5k 간격 validation	10k 간격 validation
평가	512 paths×300 validation	2,000 paths×500 final test

Notes | DQN은 200-step 인위적 rollout reset, PPO는 Gym TimeLimit(200). 할인계수 γ=β=.9703. 테스트 초기 상태 (a_0=1, y_0=H).

알고리즘·도구 및 연구기반 자료

환경과 실험은 직접 구성했으며, RL 알고리즘과 구현 도구는 아래 자료를 참조

기초 이론	Sutton, R. S. & Barto, A. G. (2018), Reinforcement Learning: An Introduction (2nd ed.).
DQN	Mnih et al. (2015), Human-level control through deep reinforcement learning, Nature.
PPO	Schulman et al. (2017), Proximal Policy Optimization Algorithms, arXiv:1707.06347.
환경 구축	Farama Foundation, Gymnasium: https://gymnasium.farama.org/
PPO 구현	Stable-Baselines3: https://stable-baselines3.readthedocs.io/
프로젝트 원본	자체 개발 소비·저축 환경, 5-seed 실험 결과 및 checkpoint: GitHub 저장소 참조

보충: 제출 파일에는 코드·모델·데이터·그림의 생성 과정을 확인할 수 있는 GitHub 링크가 포함되어 있다.